

Análisis de Componentes Principales (PCA) e Identificación de Ancestría Genética

Informe Técnico de Implementación y Resultados

Autor: Gregory Uzcategui / CI: 27.376.191

Stack tecnológico: C++17 (Eigen 3.4, fast-cpp-csv-parser), CMake,
Python 3 (matplotlib, numpy, pandas)

Algoritmo: Eigen::BDCSVD (Divide-and-Conquer)

Dataset: 30 individuos diploides $\times$ 100 SNPs, codificación $\{0, 1, 2\}$

Resumen

Este informe documenta la implementación de un pipeline computacional para el análisis de estructura poblacional mediante Componentes Principales (PCA) aplicado a datos genéticos de SNPs. Se procesó una matriz de genotipos $G \in \mathbb{R}^{100 \times 30}$ (100 SNPs, 30 individuos diploides), codificada en $\{0, 1, 2\}$. El flujo incluye: estimación de frecuencias alélicas, filtrado de SNPs constantes, normalización de Patterson (Wright-Fisher), descomposición en valores singulares (SVD) y proyección al espacio de componentes principales $PC = U\Sigma$.

Índice

1. Introducción	2
1.1. Objetivos	2
2. Marco Teórico	2
2.1. Codificación Genotípica	2
2.2. Frecuencia del Alelo Variante	3
2.3. Normalización de Patterson (Wright-Fisher)	3
2.4. Descomposición en Valores Singulares (SVD)	3
2.5. Perspectiva de Sistemas Complejos	3
3. Diseño e Implementación	4
3.1. Arquitectura del Sistema	4
3.2. Stack Tecnológico	4
3.3. Algoritmo Principal	4
3.4. Estructuras de Datos Clave	5
4. Resultados Experimentales	6
4.1. Entorno de Pruebas	6
4.2. Filtrado de SNPs Constantes	7
4.3. Varianza Explicada	7
4.4. Gráfico de Dispersión PC1 vs PC2	8
4.5. Coordenadas Principales	8
5. Análisis de Estructura Poblacional	9
5.1. Identificación de Clusters	9
5.2. Análisis de Mezcla (Admixture)	9
5.3. Verificación de la Normalización de Patterson	9
6. Conclusiones	10

1. Introducción

El estudio de la variabilidad genética humana se fundamenta en la identificación de polimorfismos de nucleótido único (SNPs), que constituyen los cambios mínimos en la secuencia del ADN. Dada la alta dimensionalidad de estos datos —donde el número de sitios genéticos suele superar por órdenes de magnitud al número de individuos—, el Análisis de Componentes Principales (PCA) se ha consolidado como la herramienta estándar para visualizar la estructura poblacional y detectar procesos de mezcla migratoria (admixture) [1].

Este proyecto implementa el flujo de cálculo numérico completo para transformar datos crudos de genotipos en un mapa de ancestría, utilizando la Descomposición en Valores Singulares (SVD) como método numérico central. La implementación se realiza en C++17 con la biblioteca Eigen 3.4 para álgebra lineal, mientras que la visualización se generó con Python, siguiendo una metodología de especificación de software (SSD) que garantiza trazabilidad entre diseño, implementación y validación.

1.1. Objetivos

- Implementar el pipeline completo de PCA genético en C++17 con precisión de doble precisión.
- Aplicar la normalización de Patterson para garantizar contribución equitativa de cada SNP.
- Calcular la SVD mediante `Eigen::BDCSVD` y proyectar los individuos al espacio PC1 vs PC2.
- Identificar visualmente clusters poblacionales y detectar individuos de mezcla (admixture).
- Documentar la arquitectura modular bajo metodología SSD con trazabilidad especificación-implementación.

2. Marco Teórico

2.1. Codificación Genotípica

Los seres humanos son organismos diploides, poseyendo dos copias de cada cromosoma. Para cada posición evaluada (SNP), se define el alelo A como la variante de referencia y el alelo a como la variante mutada. La matriz de genotipos $G \in \mathbb{R}^{n \times m}$ se codifica como:

Cuadro 1: Codificación genotípica.

Valor	Genotipo	Significado
0	AA	Homocigoto referencia (0 copias del alelo variante)
1	Aa	Heterocigoto (1 copia del alelo variante)
2	aa	Homocigoto variante (2 copias del alelo variante)

2.2. Frecuencia del Alelo Variante

Para cada SNP j (columna de G), la frecuencia del alelo variante p_j se estima como:

$$p_j = \frac{\sum_{i=1}^n G_{i,j}}{2n} \quad (1)$$

donde $n = 30$ es el número de individuos y el denominador $2n$ refleja la condición diploide.

Los SNPs constantes ($p_j = 0$ o $p_j = 1$) se descartan para evitar singularidades matemáticas en la normalización, dado que no aportan información para diferenciar poblaciones.

2.3. Normalización de Patterson (Wright-Fisher)

Para que cada sitio genético contribuya equitativamente a la varianza, se aplica la transformación:

$$\tilde{G}_{i,j} = \frac{G_{i,j} - 2p_j}{\sqrt{2p_j(1 - p_j)}} \quad (2)$$

El numerador $G_{i,j} - 2p_j$ representa la desviación del genotipo respecto al promedio poblacional bajo equilibrio Hardy-Weinberg, mientras que el denominador $\sqrt{2p_j(1 - p_j)}$ corresponde a la desviación estándar esperada bajo deriva genética neutra (modelo Wright-Fisher). El resultado es un *z-score genético* donde cada SNP tiene media ≈ 0 y varianza ≈ 1 .

2.4. Descomposición en Valores Singulares (SVD)

Definición 2.1 (Descomposición SVD). La descomposición en valores singulares de la matriz normalizada transpuesta $\tilde{G}^T \in \mathbb{R}^{n \times m'}$ es:

$$\tilde{G}^T = U \Sigma V^T \quad (3)$$

donde $U \in \mathbb{R}^{n \times n}$ y $V \in \mathbb{R}^{m' \times m'}$ son matrices ortogonales, y $\Sigma \in \mathbb{R}^{n \times m'}$ es una matriz diagonal con valores singulares $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$, siendo $r = \min(n, m')$.

Las coordenadas de los individuos en el espacio de componentes principales se obtienen mediante:

$$PC = U \Sigma \quad (4)$$

La varianza explicada por el i -ésimo componente es:

$$\text{Varianza}_i = \frac{\sigma_i^2}{\sum_{j=1}^r \sigma_j^2} \times 100 \% \quad (5)$$

2.5. Perspectiva de Sistemas Complejos

La matriz $K = \frac{1}{m'} \tilde{G} \tilde{G}^T$ es análoga a una matriz de correlación o parentesco. En física estadística, los autovectores de K representan los modos de variación dominantes del sistema. Los valores singulares σ_i indican cuánta “energía” (varianza genética) captura cada modo. El PCA permite separar la señal biológica (estructura poblacional) del ruido estocástico (deriva genética neutra).

3. Diseño e Implementación

3.1. Arquitectura del Sistema

El proyecto sigue una arquitectura modular en C++17, separando responsabilidades en 5 módulos principales (Tabla 2).

Cuadro 2: Módulos del sistema y sus responsabilidades.

Módulo	Responsabilidad	Ficheros
cargador_csv	Lectura de <code>datos_genotipo.csv</code> , validación de valores $\{0, 1, 2\}$	<code>.hpp</code> / <code>.cpp</code>
procesador_pca	Cálculo de frecuencias p_j , filtrado de SNPs constantes, normalización Patterson	<code>.hpp</code> / <code>.cpp</code>
svd_calculador	Descomposición SVD (BDCSVD) y proyección $PC = U\Sigma$	<code>.hpp</code> / <code>.cpp</code>
exportador	Escritura de <code>resultado_pca.csv</code> y <code>varianza.csv</code>	<code>.hpp</code> / <code>.cpp</code>
main	Orquestación del pipeline y logging	<code>main.cpp</code>

3.2. Stack Tecnológico

Cuadro 3: Stack tecnológico del proyecto.

Capa	Tecnología	Versión	Propósito
Cálculo numérico	C++17	ISO/IEC 14882:2017	Núcleo del pipeline
Álgebra lineal	Eigen	3.4+	Matrices densas, BDCSVD
Parser CSV	fast-cpp-csv-parser	1.0 (header-only)	Lectura de datos
Build system	CMake	3.16+	Generación de targets
Visualización	Python + matplotlib	3.10+ / 3.7+	Scatter plot PC1 vs PC2

3.3. Algoritmo Principal

El flujo completo se describe en el Algoritmo 1. La elección de `Eigen::BDCSVD` (divide-and-conquer + bidiagonalización) sobre `JacobiSVD` se justifica por su rendimiento superior en matrices de dimensiones moderadas ($n \times m'$ con $n = 30$, $m' \approx 97$).

Algorithm 1 Pipeline PCA genético mediante SVD.

Require: Matriz de genotipos $G \in \mathbb{R}^{n \times m}$ con $n = 100$ SNPs, $m = 30$ individuos

Ensure: Coordenadas principales $PC \in \mathbb{R}^{m \times r}$, varianzas explicadas, archivos CSV

- 1: Cargar G desde `datos_genotipo.csv` con validación de valores $\in \{0, 1, 2\}$
 - 2: **for** cada columna $j = 1 \dots m$ **do**
 - 3: Calcular $p_j = \sum_{i=1}^n G_{i,j} / (2n)$
 - 4: **if** $p_j = 0$ **or** $p_j = 1$ **then**
 - 5: Descartar columna j ▷ SNP constante
 - 6: **end if**
 - 7: **end for**
 - 8: Construir $G_{\text{filtrada}} \in \mathbb{R}^{n \times m'}$ con m' columnas sobrevivientes
 - 9: **for** cada elemento $G_{\text{filtrada}}(i, j)$ **do**
 - 10: $\tilde{G}_{i,j} \leftarrow (G_{\text{filtrada}}(i, j) - 2p_j) / \sqrt{2p_j(1 - p_j)}$
 - 11: **end for**
 - 12: Calcular SVD: $[U, \Sigma, V^T] = \text{BDCSVD}(\tilde{G}^T)$ con `ComputeThinU` | `ComputeThinV`
 - 13: Extraer valores singulares σ (ordenados descendente)
 - 14: $PC \leftarrow U \cdot \Sigma$ ▷ Proyección al espacio de componentes principales
 - 15: Calcular Varianza $_i = (\sigma_i^2 / \sum_j \sigma_j^2) \times 100\%$ para $i = 1, 2$
 - 16: Exportar PC a `resultado_pca.csv` y varianzas a `varianza.csv`
 - 17: Invocar script Python para generar scatter plot PC1 vs PC2
-

3.4. Estructuras de Datos Clave

La estructura `ResultadoFiltrado` almacena la matriz filtrada y las frecuencias alélicas sobrevivientes:

Listing 1: Estructura `ResultadoFiltrado` (`src/procesador_pca.hpp`).

```
1 struct ResultadoFiltrado {
2     std::vector<double> val_filtrados;    // Matriz filtrada (
        column-major)
3     std::vector<double> p;                // Frecuencias p_j de
        columnas sobrevivientes
4     std::vector<int> indices_originales; // Indices j originales
        conservados
5     int n_snps_filtrados;                // m' = columnas que
        sobreviven
6 };
```

La estructura `ResultadoNormalizado` almacena la matriz transformada:

Listing 2: Estructura `ResultadoNormalizado` (`src/procesador_pca.hpp`).

```
1 struct ResultadoNormalizado {
2     std::vector<double> g_tilde;          // Matriz normalizada (
        column-major)
3     int n_snps_filtrados;                // SNPs despues de
        filtrado
4     int n_individuos;                   // Numero de individuos
5     std::vector<double> p;              // Frecuencias usadas (
        copia para referencia)
6 };
```

La proyección PCA se implementa como multiplicación matricial directa:

Listing 3: Proyeccion PCA: $PC = U * \text{Sigma}$ (src/svd_calculador.cpp).

```
1 Eigen::MatrixXd calcularPCA(const std::vector<double>& g_tilde,
2                             int n_snps_filtrados, int
3                             n_individuos,
4                             Eigen::VectorXd& valores_singulares,
5                             double& var_pc1, double& var_pc2) {
6     // 1. Convertir vector column-major a Eigen::MatrixXd
7     Eigen::MatrixXd G_tilde = SnpMatFromVector(n_snps_filtrados,
8         n_individuos, g_tilde);
9
10    // 2. Transponer: individuos como filas
11    Eigen::MatrixXd G_tilde_T = G_tilde.transpose(); //
12        n_individuos x n_snps_filtrados
13
14    // 3. Calcular SVD con BDCSVD
15    Eigen::BDCSVD<Eigen::MatrixXd> svd(G_tilde_T,
16        Eigen::ComputeThinU | Eigen::ComputeThinV);
17
18    Eigen::MatrixXd U = svd.matrixU();
19    Eigen::VectorXd sigma = svd.singularValues();
20
21    // 4. Proyectar:  $PC = U * \text{Sigma}$ 
22    Eigen::MatrixXd PC = U * sigma.asDiagonal();
23
24    // 5. Calcular varianza explicada
25    double sum_sigma2 = sigma.array().square().sum();
26    var_pc1 = (sigma(0)*sigma(0) / sum_sigma2) * 100.0;
27    var_pc2 = (sigma(1)*sigma(1) / sum_sigma2) * 100.0;
28
29    valores_singulares = sigma;
30    return PC;
31 }
```

4. Resultados Experimentales

4.1. Entorno de Pruebas

- **Hardware:** CPU x64, compilación Release con optimizaciones.
- **Software:** C++17, Eigen 3.4 (header-only), fast-cpp-csv-parser, CMake 3.16+.
- **Dataset:** datos_genotipo.csv con 100 SNPs $\times$ 30 individuos, valores $\{0, 1, 2\}$.
- **Parámetros:** Filtrado de SNPs constantes, normalización Patterson, SVD completa.

4.2. Filtrado de SNPs Constantes

Del total de 100 SNPs analizados, 3 fueron descartados por ser constantes ($p_j = 0$ o $p_j = 1$), resultando en $m' = 97$ SNPs efectivos para el análisis. Este filtrado garantiza que el denominador de la normalización de Patterson nunca se anule, evitando singularidades matemáticas.

4.3. Varianza Explicada

Cuadro 4: Varianza explicada por los componentes principales.

Componente	Varianza Explicada (%)
PC1	57.11
PC2	3.77

La suma de varianza explicada por PC1 y PC2 captura el 60,88 % de la variabilidad genética total. PC1 domina claramente la estructura poblacional, capturando más de la mitad de la varianza genética. Este patrón es consistente con estudios de estructura poblacional donde el primer componente principal separa las poblaciones más divergentes [1].

4.4. Gráfico de Dispersión PC1 vs PC2




Figura 1: Scatter plot de PC1 vs PC2. Cada punto representa un individuo. Se observan tres grupos bien definidos: Cluster A (derecha, $PC1 \approx +10$), Cluster B (izquierda, $PC1 \approx -11$), y un grupo intermedio de individuos de mezcla (centro, $PC1 \approx 0$).

4.5. Coordenadas Principales

Cuadro 5: Coordenadas PC1 y PC2 para los 30 individuos analizados.

Individuo	PC1	PC2	Individuo	PC1	PC2
Individuo_1	+9,890	+0,977	Individuo_16	-11,368	-0,758
Individuo_2	+11,088	+0,084	Individuo_17	-10,592	-1,194
Individuo_3	+11,814	+1,022	Individuo_18	-11,669	+1,025
Individuo_4	+9,873	-2,176	Individuo_19	-11,105	-1,729
Individuo_5	+9,245	-2,245	Individuo_20	-10,069	+0,734
Individuo_6	+10,861	+0,722	Individuo_21	-10,752	-2,820
Individuo_7	+11,252	+0,519	Individuo_22	-10,707	+1,843
Individuo_8	+9,602	-2,137	Individuo_23	-11,123	-0,646
Individuo_9	+10,678	+0,182	Individuo_24	-10,361	+0,408
Individuo_10	+11,522	+0,571	Individuo_25	+1,417	+5,039
Individuo_11	+10,133	-2,449	Individuo_26	-0,633	+1,449
Individuo_12	+12,292	+0,308	Individuo_27	+0,454	+2,573
Individuo_13	-11,870	+0,289	Individuo_28	-0,743	-3,668
Individuo_14	-10,668	-0,755	Individuo_29	+0,403	-5,872
Individuo_15	-9,130	+1,112	Individuo_30	+0,269	+7,592

5. Análisis de Estructura Poblacional

5.1. Identificación de Clusters

Los resultados obtenidos revelan una estructura poblacional tripartita claramente definida:

1. **Cluster A — Población de referencia 1 (Individuos 1–12):** Ubicados en el semiplano derecho con $PC1 \approx +10$ y $PC2$ disperso alrededor de 0. Este grupo muestra alta cohesión interna, con desviaciones estándar de $PC1$ y $PC2$ de 0,89 y 1,15 respectivamente. La homogeneidad genética de la población sugiere una población con historia reproductiva aislada.
2. **Cluster B — Población de referencia 2 (Individuos 13–24):** Ubicados en el semiplano izquierdo con $PC1 \approx -11$ y $PC2$ disperso alrededor de 0. Similarmente cohesivo, con desviaciones estándar de 0,73 ($PC1$) y 1,16 ($PC2$). La separación casi simétrica respecto al origen en $PC1$ indica una divergencia genética equilibrada entre ambas poblaciones.
3. **Grupo Intermedio — Individuos de mezcla (Individuos 25–30):** Posicionados en la zona central del gráfico ($PC1 \approx 0$), con $PC2$ mostrando alta dispersión vertical ($\sigma_{PC2} = 4,78$). Esta configuración es el sello distintivo que define *admixture* o mezcla genética.

5.2. Análisis de Mezcla (Admixture)

La posición intermedia de los Individuos 25–30 en el eje $PC1$ es evidencia directa de ancestros compartidos entre las Poblaciones A y B. En términos de su historia genética, estos individuos son descendientes de eventos de hibridación o migración entre las dos poblaciones parentales.

El patrón observado se interpreta como sigue:

- **PC1 como eje de divergencia poblacional:** Captura la dirección de máxima varianza genética, que en este caso separa las dos poblaciones parentales. Los individuos de mezcla tienen $PC1 \approx 0$ porque heredan aproximadamente la misma proporción de alelos de ambas poblaciones.
- **PC2 como eje de variación secundaria:** La alta dispersión en $PC2$ de los individuos intermedios refleja la variabilidad en la proporción exacta de mezcla. Por ejemplo, el Individuo_30 ($PC2 = +7.59$) y el Individuo_29 ($PC2 = -5.87$) representan extremos dentro del espectro de mezcla, posiblemente con diferentes proporciones de ancestros A y B.

5.3. Verificación de la Normalización de Patterson

El test de verificación confirmó que la media de cada columna de $\tilde{G}$ es $\|\text{media}\|_\infty < 10^{-10}$, validando que la normalización de Patterson produce z-scores genéticos centrados. La varianza por columna se aproxima a 1, consistente con el modelo Wright-Fisher neutro.

6. Conclusiones

1. Se implementó exitosamente un pipeline completo de PCA genético en C++17, desde la carga de datos genotípicos hasta la proyección y visualización de componentes principales, con arquitectura modular documentada bajo metodología SSD.
2. La normalización de Patterson garantizó que cada SNP contribuyera equitativamente al análisis, evitando el sesgo por frecuencias alélicas extremas y validando la hipótesis de deriva genética neutra.
3. El algoritmo BDCSVD de Eigen demostró ser numéricamente estable, convergiendo sin excepciones y produciendo una factorización ortogonal con precisión de máquina.
4. Los resultados revelan una estructura poblacional tripartita: dos poblaciones parentales bien diferenciadas (Clusters A y B) y un grupo de 6 individuos intermedios que evidencian procesos de mezcla genética (admixture), consistentes con eventos históricos de migración o hibridación.
5. PC1 captura el 57,11 % de la varianza genética total y constituye el eje principal de divergencia poblacional, mientras que PC2 (3,77 %) captura la variación secundaria, incluyendo la dispersión dentro del grupo de mezcla.

Referencias

- [1] Patterson, N., Price, A. L., & Reich, D. (2006). Population structure and eigenanalysis. *PLoS Genetics*, 2(12), e190.
- [2] Price, A. L., et al. (2006). Principal components analysis corrects for stratification in genome-wide association studies. *Nature Genetics*, 38(8), 904–909.
- [3] Trefethen, L. N., & Bau III, D. (1997). *Numerical Linear Algebra*. SIAM.
- [4] Golub, G. H., & Van Loan, C. F. (2013). *Matrix Computations* (4th ed.). Johns Hopkins University Press.
- [5] Eigen Documentation. *SVD Module*. https://eigen.tuxfamily.org/dox/group__SVD__Module.html